

● gpubpf ● NVBit ◆ gpubpf + array | mean

(a) P40, Llama 1B prefill



(b) RTX 5090, TinyLlama-1.1B prefill

